Retos Avanzados de MapReduce en Hadoop 3.3.6

Equipo 9

Ayala Carrazco Said Giuliano
Carmona Capula Andrés Tadeo
Hernandez Huerta Ari Leonardo

Agenda y ¿Qué hace cada ejemplo?

1. ¿Qué hace cada ejemplo y caso real donde sirve?
2. ¿Cómo funciona? Diagramas Map y Reduce
3. Demo en vivo: comandos, datos y resultados
4. Mini ejercicio y solución

secondarysort	Ordena por llave primaria y secundaria. **Caso real:** historial de compras ordenado por cliente y monto.
join	Une dos datasets por llave, inner y outer join. **Caso real:** clientes con pedidos o alumnos con calificaciones.
dbcount	Lee tabla SQL, cuenta URLs y escribe total. **Caso real:** analítica web con bitácora de accesos.

¿Cómo funciona secondarysort? ?

Diagrama Map y Reduce

ENTRADA

Líneas con dos enteros separados por espacio.

```
3 8
3 1
1 7
2 4
3 5
2 2
1 3
```

1. MAP

Emite llave compuesta (K1, K2) y valor K2.

(3,8) → 8
(3,1) → 1
(1,7) → 7
(2,4) → 4
(3,5) → 5
(2,2) → 2
(1,3) → 3

2. SHUFFLE / SORT

Ordena por (K1, K2) y agrupa solo por K1.

(1,3) → 3
(1,7) → 7

(2,2) → 2
(2,4) → 4

(3,1) → 1
(3,5) → 5
(3,8) → 8

3. REDUCE

Recibe grupos ordenados por K1. y los escribe.

K1 = 1
(1,3) (1,7)
1 : 3 7

K1 = 2
(2,2) (2,4)
2 : 2 4

K1 = 3
(3,1) (3,5) (3,8)
3 : 1 5 8

SALIDA

Pares de enteros ordenados por K2 dentro de cada K1.

1 : 3 7
2 : 2 4
3 : 1 5 8

Demo en vivo secondarysort

(comandos, entrada, resultado)

Hadoop 3.3.6 en contenedor Debian

1 **Crear entrada**

```
cat > input.txt <<'EOF'
3 8
1 5
2 3
3 1
2 9
1 2
2 1
EOF
```

2 **Ejecutar job**

```
hadoop jar secondarysort.jar \
SecondarySort input.txt output
```

3 **Mostrar resultado**

```
hadoop fs -cat output/part-r-00000
```

ENTRADA (input.txt)

```
3 8
1 5
2 3
3 1
2 9
1 2
2 1
```

RESULTADO ESPERADO

```
1 2
1 5
----------
2 1
2 3
2 9
----------
3 1
3 8
```

Ordenado por llave primaria. Valores en orden ascendente dentro de cada grupo.

¿Cómo funciona join?

DIAGRAMA MAP Y REDUCE

Map-Side Join con CompositeInputFormat.
Los archivos entran ordenados y se unen **antes del Map.**
Map y Reduce son **identidad**, lo que ahorra tráfico.

EJEMPLO: INNER JOIN

clientes (ordenado)	
1	Ana
2	Luis
3	Marta
4	Pedro

pedidos (ordenado)	
1	1200
3	850
4	300

resultado (inner join)		
1	Ana	1200
3	Marta	850
4	Pedro	300

EJEMPLO: OUTER JOIN

clientes (ordenado)	
1	Ana
2	Luis
3	Marta
4	Pedro

pedidos (ordenado)	
1	1200
3	850
5	600

resultado (outer join)		
1	Ana	1200
2	Luis	NULL
3	Marta	850
4	Pedro	NULL
5	NULL	600

Demo en vivo

join

(comandos, entrada, resultado)

- Preparamos datos de **clientes y pedidos** creación de directorios y archivos.
- Ejecutamos el job **join** con opción **inner join** y **outer join**.
- Obtenemos resultados **inner join** mostramos coincidencias encontradas.
- Obtenemos resultados **outer join** incluye registros sin par.

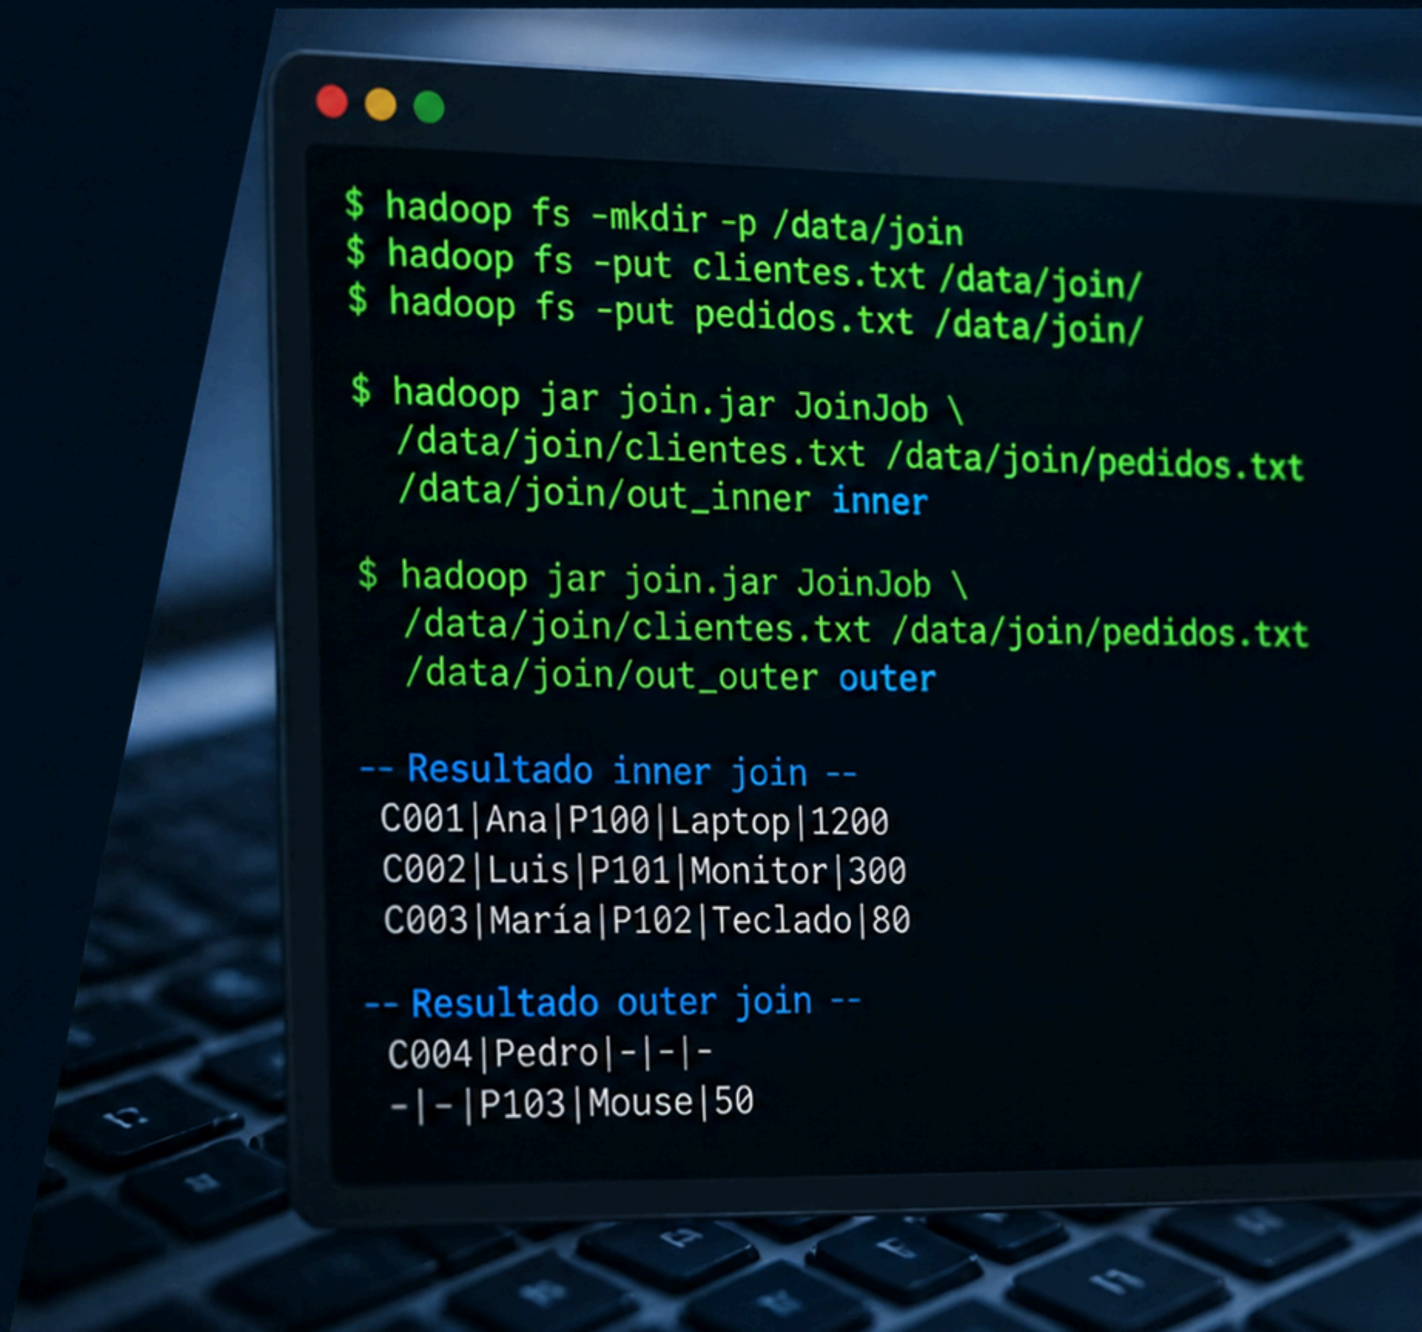

Bonus dbcount

Cuenta visitas URL leyendo tabla SQL **HAccess** y escribe el total en tabla SQL **Pageview.**

1 Entrada
filas tabla SQL HAccess (URL, referrer, tiempo)

→

2 Map
emite (URL, 1)

→

3 Shuffle
agrupa todos los 1 por URL

→

4 Reduce
suma los 1 y escribe total en tabla SQL Pageview

Ejecuta el job dbcount

```
hadoop jar dbcount.jar dbcount \
--lib hsqldb.jar --input HAccess --output Pageview
```

Resultado esperado

60 visitas totales leídas y sumadas

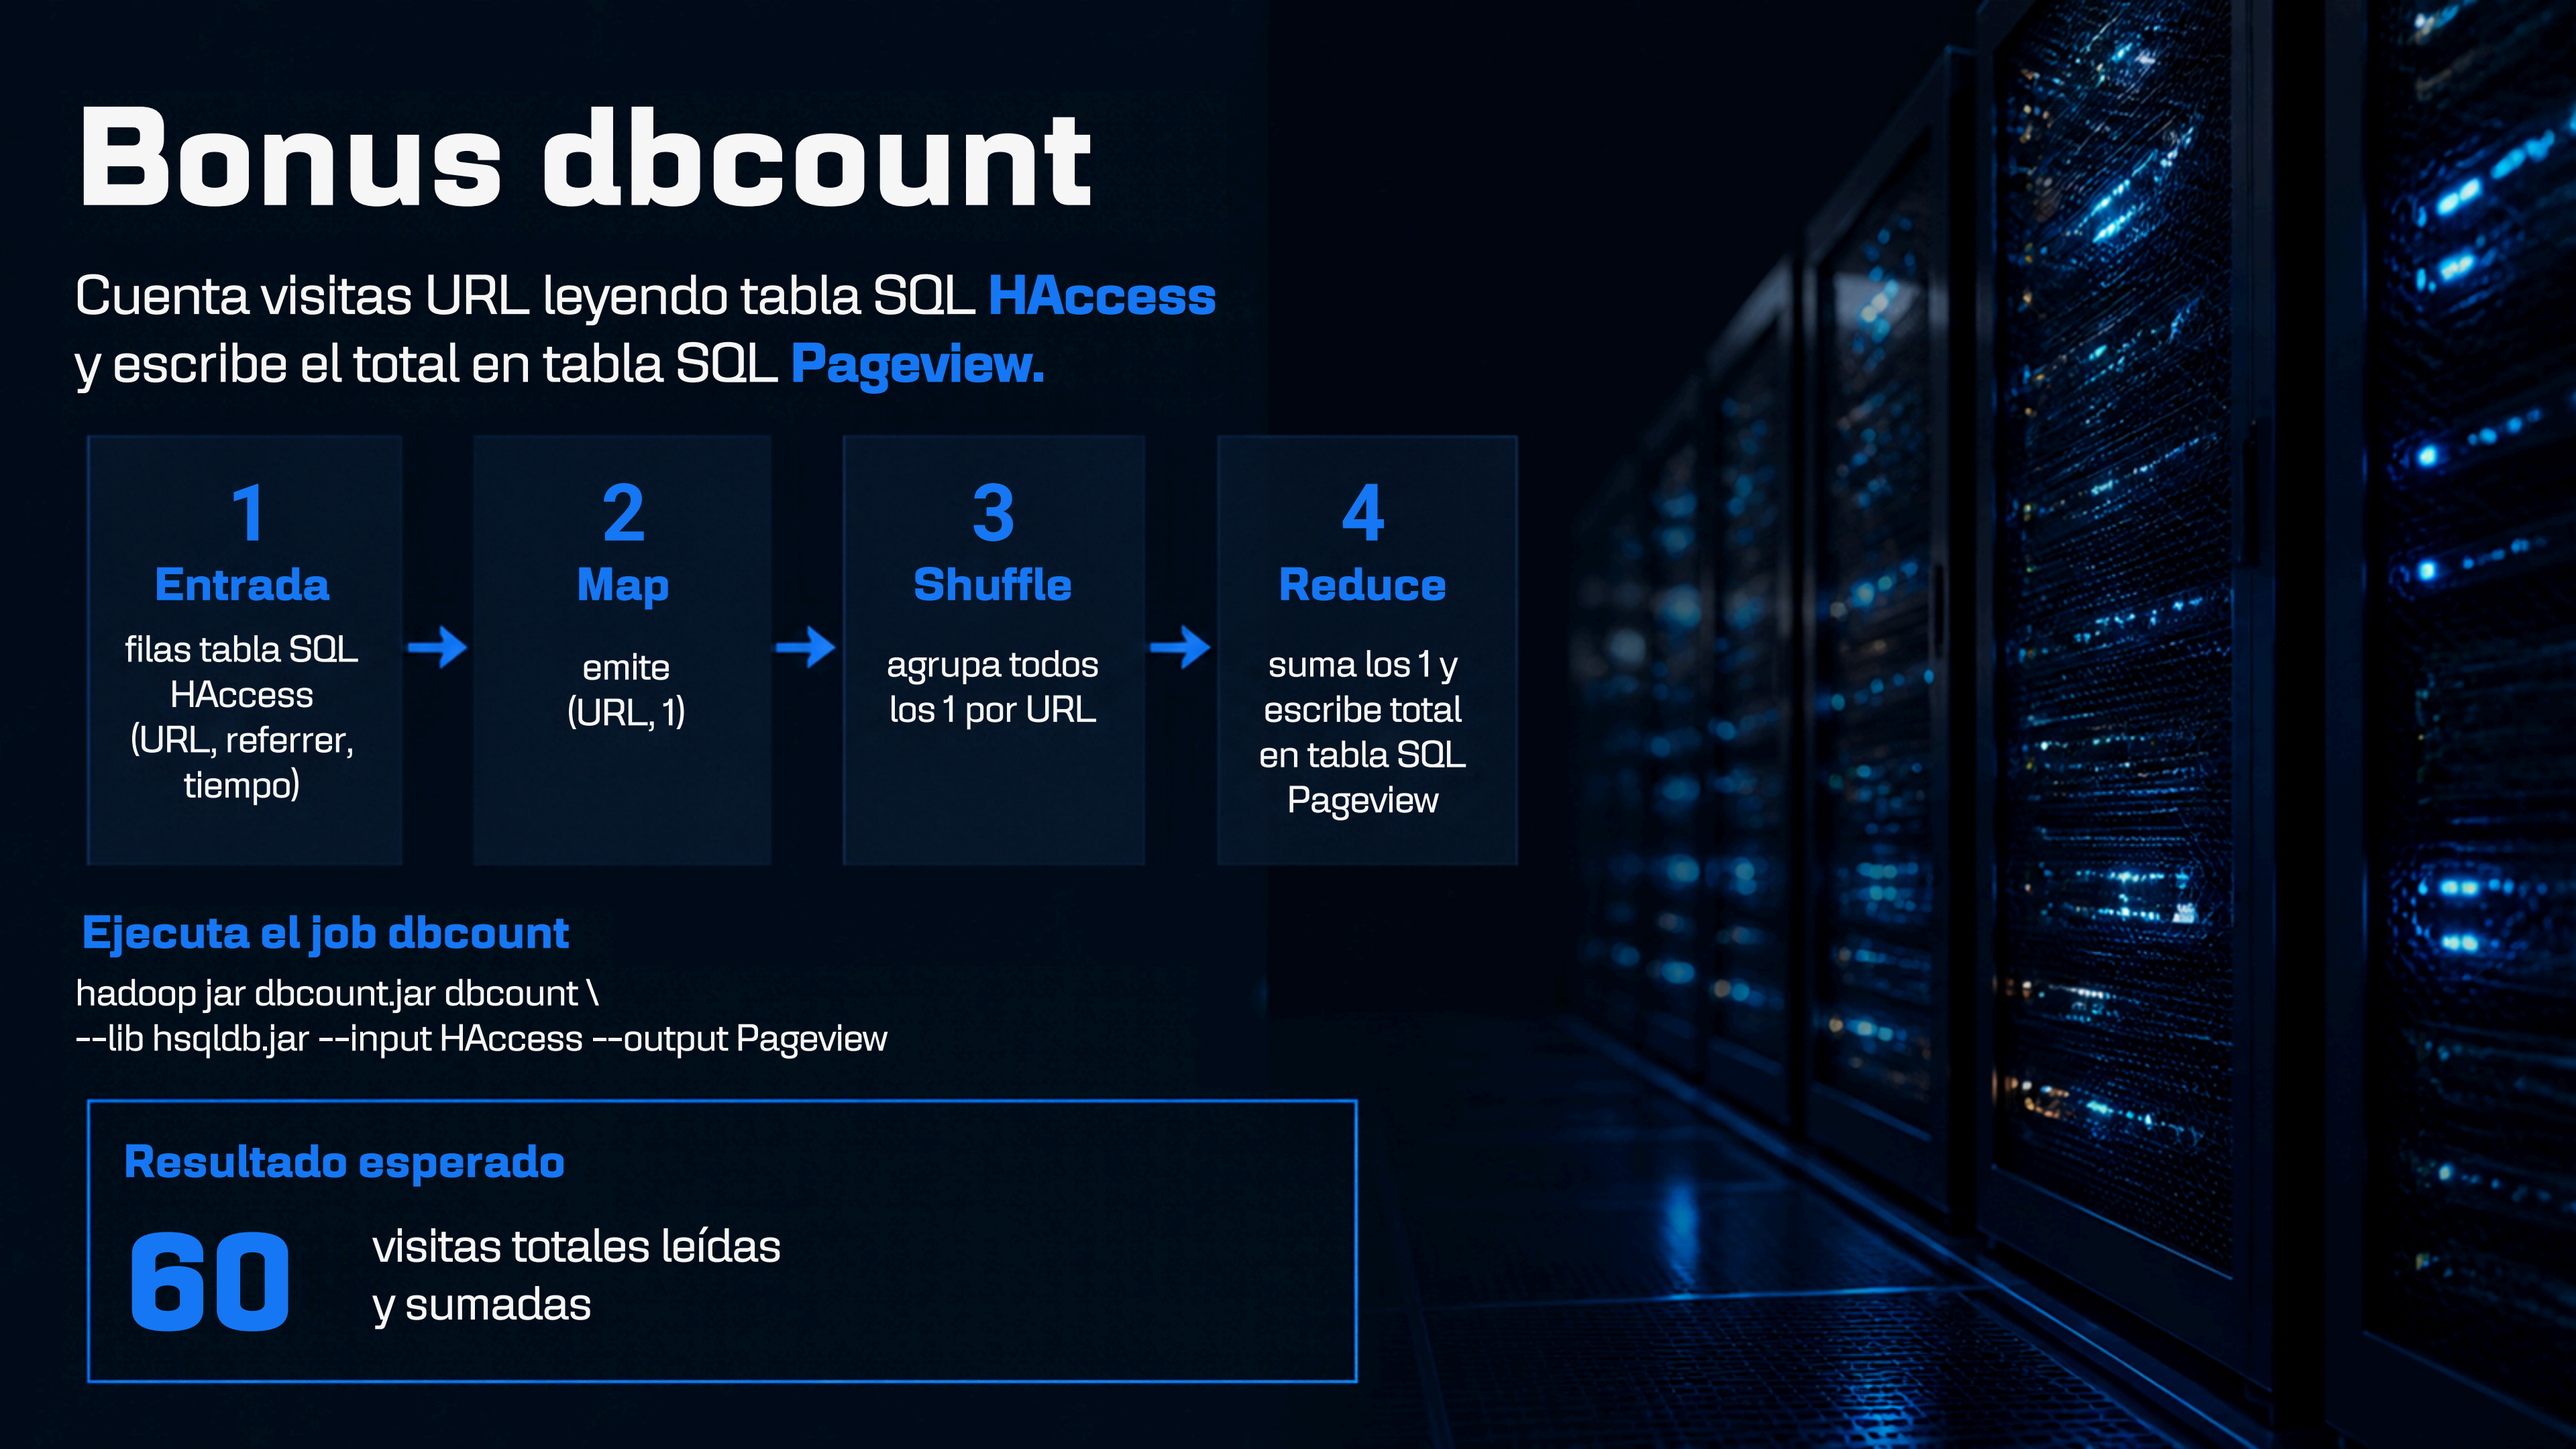

Mini ejercicio para compañeros

Dos partes. Piensa antes de ejecutar en el contenedor.

01

secondarysort

Ejecuta el job con datos nuevos.
¿Cuántas líneas separadoras genera?
¿Cómo se comporta la llave compuesta?

02

join

Ejecuta el join inner con alumnos y calificaciones.
¿Qué llaves aparecen y qué cambia frente a un outer?
¿Qué efecto tiene el dato erróneo “8 x” en secondarysort?

Solución del mini ejercicio

1	3 líneas separadoras por cada llave primaria. Ordena por llave compuesta, agrupa solo por primaria.	100 1 150 100 2 200 100 3 300 --- 200 1 80 200 2 90 200 3 120 ---
2	La salida inner solo muestra llaves con coincidencia. Outer incluye todas. La unión ocurre antes del Map.	INNER: 100 A 150 150 200 B 80 80 OUTER: 100 A 150 150 200 B 80 80 300 C NULL 50
3	Error NumberFormatException: secondarysort espera enteros y no puede parsear "x".	java lang NumberFormatException: For input string: "x" at java lang,Integer,parseInt ... Caused by: For input string: "x"